

TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG – ĐẠI HỌC BÁCH KHOA HÀ NỘI

HỌC PHẦN: QUẢN TRỊ DỮ LIỆU VÀ TRỰC QUAN HÓA (IT5425)

KẾ HOẠCH TOÀN DIỆN TRIỂN KHAI BÀI TẬP LỚN

Đề tài: Kiến Trúc Data Lakehouse Đa Tầng, Hệ Thống Thu Thập Dữ Liệu Lớn
Đa Nguồn & Nền Tảng Trực Quan Hóa Giám Sát Dây chuyền Nhà Máy Chế
Biến Sữa Thông Minh (Smart Dairy Factory) Kết Hợp Mô Hình Tuyến Tính Dự
Báo Chất Lượng

Nhóm Kỹ thuật Dữ liệu Công nghiệp (Industrial Data Engineering Group) – Lớp IT5425

Quy mô nhóm: 07 sinh viên | Phân bổ đóng góp: $\approx 14.3\%$ / thành viên (Tổng 100%)

Năm học 2024 – 2025

Tóm tắt nội dung

Tài liệu này xác lập bản kế hoạch kỹ thuật toàn diện, phương pháp luận thực thi và phân bổ trách nhiệm khép kín cho Bài tập lớn học phần *Quản trị Dữ liệu và Trực quan hóa (IT5425)* tại Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội. Đề tài tập trung vào chủ đề “*Linear models for factories (garment, food or dairy product)*” với trọng tâm cốt lõi đặt vào bài toán **Quản trị Dữ liệu Lớn (Big Data Management)** và **Trực quan hóa Dữ liệu Công nghiệp Tương tác (Industrial Visual Analytics)**. Cụ thể, nhóm xây dựng giải pháp cho nhà máy chế biến sữa và sản phẩm từ sữa thông minh (*Smart Dairy Factory Processing Plant*): thiết kế kiến trúc **Enterprise Data Lakehouse** đa tầng (Medallion Architecture: Bronze – Silver – Gold) dựa trên định dạng bảng giao dịch ACID **Delta Lake / Apache Iceberg** lưu trữ trên cụm MinIO S3-compatible, đáp ứng tiêu chuẩn truy xuất nguồn gốc và kiểm toán nghiêm ngặt của ngành thực phẩm (ISO 22000, HACCP, FDA 21 CFR Part 11 Audit Trail). Hệ thống xây dựng cụm thu thập dữ liệu lớn phân tán (**Distributed Crawling Cluster** với Scrapy, Playwright và API Streaming) để thu thập đa nguồn từ giá nông sản sữa thế giới (Global Dairy Trade, Chicago Mercantile Exchange), chỉ số khí hậu thời tiết vùng chăn nuôi cung ứng (Open-Meteo API) đến các cảnh báo thu hồi an toàn thực phẩm toàn cầu. Khâu quản trị dữ liệu được tự động hóa bằng **Great Expectations** (Data Contracts kiểm soát tính toàn vẹn vật lý và sinh hóa sữa, tự động tạo Data Docs HTML) kết hợp theo dõi nguồn gốc dữ liệu **OpenLineage**. Dữ liệu được mô hình hóa theo cấu trúc Star Schema tối ưu và tăng tốc bằng động cơ phân tích véc-tơ hóa nội tiến trình **chDB (ClickHouse C++ engine)** cùng khung xử lý đa luồng **Polars**. Khám phá dữ liệu sản xuất (Manufacturing EDA) kết hợp kiểm soát quá trình thống kê **SPC (Shewhart, CUSUM, EWMA)** và đánh giá năng lực dây chuyền (C_p, C_{pk}). Mô hình tuyến tính ứng dụng (Linear Models) giữ vai trò dự báo thực dụng: Hồi quy tuyến tính có điều chuẩn (Ridge/Lasso) dự báo tỷ lệ thu hồi chất khô (Fat & Protein Yield), Hồi quy Logistic dự báo xác suất lỗi lô sản phẩm (Defective Batch Risk), kết hợp ước lượng hợp lý cực đại (**MLE**) và thuật toán **EM (Expectation-Maximization)** để xử lý bài toán dữ liệu cảm biến đo lường khuyết

thiếu và ước lượng trạng thái vận hành ẩn của thiết bị. Cuối cùng, toàn bộ hệ thống được trực quan hóa thông qua ứng dụng Web tương tác đa tầng (**Plotly Dash Industrial Platform**) hỗ trợ giám sát OEE thời gian thực, bản đồ nhiệt chuỗi cung ứng lạnh và bộ giả lập thông số dây chuyền *What-If Quality Simulator*. Kế hoạch phân bổ chính xác cho 07 thành viên, mỗi thành viên đảm nhận $\approx 14.3\%$ khối lượng công việc, chịu trách nhiệm khép kín từ lý thuyết, dữ liệu, mã nguồn đến bảo vệ trước hội đồng.

Mục lục

1	Đề Tài Chính Thức và Quy Tắc Sống Còn Của Dự Án	3
1.1	Thông Tin Đề Tài Khóa Học	3
1.2	Định Hướng Trọng Tâm: Quản Trị Dữ Liệu & Trực Quan Hóa	3
1.3	Bốn Quy Tắc Sống Còn Quyết Định Đánh Giá Cá Nhân	3
2	Tổng Quan Bài Toán Nghiệp Vụ & Hệ Sinh Thái Dữ Liệu Nhà Máy Sữa	4
2.1	Bối Cảnh Nhà Máy Chế Biến Sữa Thông Minh (Smart Dairy Factory)	4
2.2	Bốn Câu Hỏi Nghiên Cứu Nghiệp Vụ Cốt Lõi	5
2.3	Chi Tiết Các Nguồn Dữ Liệu Lớn Trong Dự Án	5
3	Kiến Trúc Quản Trị Dữ Liệu Lớn (Data Lakehouse) & Hệ Thống Thu Thập	6
3.1	Sơ Đồ Kiến Trúc Smart Factory Data Lakehouse	7
3.2	Các Điểm Đột Phá Về Mặt Kiến Trúc Dữ Liệu	7
3.3	Thiết Kế Mô Hình Kho Dữ Liệu Nhà Máy (Industrial Star Schema)	8
3.4	Cấu Trúc Cây Thư Mục Dự Án (Repository Structure)	9
4	Ma Trận Phân Công 07 Hợp Phần Chuyên Môn Cho 07 Thành Viên	9
4.1	Bảng Tổng Hợp Trách Nhiệm & Tỷ Lệ Đóng Góp (07 Thành Viên)	9
4.2	Đặc Tả Chi Tiết Từng Phân Hệ Kỹ Thuật (P1 $\rightarrow$ P7)	9
4.2.1	Phân Hệ 1: Enterprise Data Lakehouse Architecture, Delta Lake ACID & Storage Engine	9
4.2.2	Phân Hệ 2: Distributed Web Crawling, Playwright Scraping & Multi-source Ingestion	11
4.2.3	Phân Hệ 3: Industrial Data Governance, Great Expectations Data Contracts & Data Lineage	12
4.2.4	Phân Hệ 4: Analytical Data Marts (Star Schema), Polars Pipeline & chDB ClickHouse Engine	13
4.2.5	Phân Hệ 5: Manufacturing EDA, Statistical Process Control (SPC) & Capability (C_p, C_{pk})	14
4.2.6	Phân Hệ 6: Applied Statistical Linear Modeling: Linear/Logistic, MLE & EM Algorithm	15
4.2.7	Phân Hệ 7: Industrial Visual Analytics Dashboard (Plotly Dash), What-If Simulator & Storytelling	16
5	Sơ Đồ Chuyển Giao & Mạng Lưới Quan Hệ Tiên Quyết Giữa 07 Thành Viên	17
6	Lộ Trình Triển Khai Chi Tiết (06 Sprints / 15 Tuần)	18
7	Quy Chuẩn Đồ Họa & Trực Quan Hóa Dữ Liệu Công Nghiệp	18
8	Chiến Thuật Ghi Điểm Tuyệt Đối Trong Phiên Vấn Đáp	20
9	Kết Luận	20

QUY TẮC ĐÁNH GIÁ VÀ BẢO VỆ ĐỒ ÁN (CHỈ ĐẠO TỪ GIẢNG VIÊN)

- Đánh giá cá nhân trên sản phẩm nhóm:** Giảng viên thực hiện **vấn đáp và chấm điểm hoàn toàn độc lập cho từng cá nhân**. Điểm số của từng thành viên phụ thuộc trực tiếp vào mức độ thông hiểu bản chất kỹ thuật, khả năng giải trình dòng lệnh (line-by-line code) và ý nghĩa thực tiễn công nghiệp của biểu đồ/module trong phần phụ trách.
- Cấu trúc 07 phân hệ chuyên môn độc lập & Khép kín (End-to-End):** Dự án phân rã chính xác thành 07 phân hệ kỹ thuật tương ứng hoàn hảo cho 07 thành viên (TV 1 đến TV 7). Mỗi thành viên chịu trách nhiệm $\approx 14.3\%$ khối lượng công việc toàn dự án (tổng cộng 100%).
- Tuyệt đối nghiêm cấm phân chia theo bề nổi:** Không chấp nhận mô hình phân chia công việc thụ động như “chỉ vẽ slide”, “chỉ làm tài liệu word”, hay “chỉ chạy script có sẵn”. Mỗi thành viên phải tự thực hiện toàn vẹn chu trình trong phân hệ của mình:
 - Nắm vững cơ sở lý thuyết toán học, kiến trúc dữ liệu và thuật toán liên quan.
 - Trực tiếp lập trình mã nguồn (crawling, ETL, Delta Lake, chDB, Great Expectations, mô hình hóa, hoặc Dash UI).
 - Thiết kế trực quan hóa chuẩn mực theo quy tắc đồ họa kỹ thuật công nghiệp.
 - Soạn thảo chương báo cáo tương ứng và slide thuyết trình chuyên môn.
 - Độc lập thuyết trình và bảo vệ phản biện trước các câu hỏi vấn đáp của hội đồng.
- Tính thực chất và liên kết hữu cơ:** Các phân hệ dữ liệu, mô hình và trực quan hóa phải giao tiếp chặt chẽ thông qua các hợp đồng dữ liệu (Data Contracts, Schemas, API connectors), tạo thành một sản phẩm công nghiệp hoàn chỉnh chạy thông suốt từ đầu vào đến đầu ra.

2 Tổng Quan Bài Toán Nghiệp Vụ & Hệ Sinh Thái Dữ Liệu Nhà Máy Sữa


2.1 Bối Cảnh Nhà Máy Chế Biến Sữa Thông Minh (Smart Dairy Factory)

Ngành công nghiệp chế biến sữa (Dairy Processing) là một trong những ngành sản xuất đòi hỏi tiêu chuẩn nghiêm ngặt nhất về quản lý chất lượng và kiểm soát an toàn thực phẩm. Quy trình sản xuất các sản phẩm sữa tiệt trùng UHT, sữa thanh trùng, sữa chua và phô mai bao gồm các công đoạn liên hoàn:

- Tiếp nhận sữa tươi nguyên liệu từ các trang trại chăn nuôi bò sữa đối tác.
- Kiểm tra hóa lý và vi sinh ban đầu (hàm lượng chất béo, protein, độ acid, tế bào soma, dư lượng kháng sinh).
- Tiền xử lý: Làm lạnh bảo quản $\leq 4^{\circ}\text{C}$, ly tâm tách béo, chuẩn hóa tỷ lệ béo/protein, đồng hóa (Homogenization) ở áp suất 150–250 bar.
- Xử lý nhiệt: Tiệt trùng UHT ở nhiệt độ cực cao $137\text{--}142^{\circ}\text{C}$ trong 3–5 giây (hoặc thanh trùng $72\text{--}75^{\circ}\text{C}$ trong 15 giây).
- Chiết rót vô trùng (Aseptic Filling) vào bao bì hộp giấy tiệt trùng đa lớp và đóng thùng carton.
- Lưu kho lạnh và vận chuyển phân phối qua chuỗi cung ứng lạnh (Cold Chain Logistics).

Thách thức cốt lõi trong nhà máy là sự biến động phức tạp của nguyên liệu đầu vào và điều kiện vận hành thiết bị:

- Khối lượng dữ liệu cảm biến khổng lồ và liên tục:** Các cảm biến nhiệt độ, áp suất, lưu lượng dòng chảy (Flow rate), độ dẫn điện (Conductivity), độ pH gắn dọc dây chuyền tiệt



Hình 1: Quy trình công nghệ chế biến sữa UHT và các điểm kiểm soát tới hạn (CCP) trong nhà máy.

trùng và chiết rót phát sinh hàng triệu điểm đo mỗi ca sản xuất.

- **Phân mảnh nguồn dữ liệu:** Dữ liệu kiểm tra chất lượng phòng thí nghiệm (LIMS) nằm ở cơ sở dữ liệu quan hệ, dữ liệu vận hành máy nằm ở hệ thống SCADA/PLC, dữ liệu quản lý lô nằm ở ERP/MES, trong khi các yếu tố tác động bên ngoài (thời tiết vùng nuôi bò, giá sữa nguyên liệu thế giới, cảnh báo an toàn thực phẩm) lại nằm rải rác trên Internet.
- **Yêu cầu truy xuất nguồn gốc tức thì (Instant Traceability):** Khi một mẫu sữa thành phẩm có dấu hiệu lỗi chất lượng (ví dụ: kết tủa protein hoặc nhiễm khuẩn), kỹ sư phải có khả năng truy vết ngược từ mã lô (Batch ID) về thông số cảm biến từng giây của tháp tiệt trùng, bồn chứa nguyên liệu, và trang trại cung cấp sữa trong vòng dưới 3 giây theo quy chuẩn HACCP và ISO 22000.

2.2 Bốn Câu Hỏi Nghiên Cứu Nghiệp Vụ Cốt Lõi

Dự án được thiết kế để giải quyết trọn vẹn bốn bài toán thực tiễn:

1. **Hạ tầng dữ liệu lớn & Thu thập đa nguồn:** Làm thế nào để xây dựng một kiến trúc Data Lakehouse thống nhất, vừa có khả năng cào/thu thập dữ liệu giá thị trường và thời tiết bên ngoài theo định kỳ, vừa lưu trữ và quản lý hàng chục triệu bản ghi cảm biến bên trong với đầy đủ khả năng kiểm toán giao dịch ACID và Time-Travel?
2. **Quản trị chất lượng & Phát hiện bất thường quy trình:** Làm thế nào để tự động hóa việc kiểm tra hợp đồng dữ liệu (Data Contracts) ngay khi nạp, loại bỏ dữ liệu rác, khử nhiễu cảm biến và phát hiện sớm các hiện tượng mất ổn định dây chuyền thông qua kiểm soát quá trình thống kê (SPC)?
3. **Dự báo chất lượng bằng mô hình tuyến tính:** Mối quan hệ giữa các thông số công nghệ (nhiệt độ UHT, áp suất đồng hóa, lưu lượng) và thuộc tính chất lượng (tỷ lệ thu hồi chất khô, xác suất lỗi lô sản phẩm) được lượng hóa như thế nào thông qua Hồi quy tuyến tính có điều chuẩn và Hồi quy Logistic? Thuật toán EM giải quyết bài toán cảm biến khuyết thiếu hoặc phân cụm trạng thái ẩn của thiết bị ra sao?
4. **Thực quan hóa hỗ trợ ra quyết định công nghiệp:** Làm thế nào để xây dựng giao diện tương tác phản ứng cao cho phép giám đốc nhà máy theo dõi OEE, kỹ sư giám sát biểu đồ SPC thời gian thực, và cho phép chuyên viên phòng R&D sử dụng bộ giả lập What-if Simulator để tối ưu hóa công thức sản xuất?

2.3 Chi Tiết Các Nguồn Dữ Liệu Lớn Trong Dự Án

Hệ sinh thái dữ liệu của dự án là sự kết hợp thực tế giữa dữ liệu nội bộ nhà máy và dữ liệu thu thập phân tán từ Internet:

- **Nguồn 1 – Dữ liệu Cảm biến Vận hành Dây chuyền (IoT Telemetry Data):** Dữ liệu chuỗi thời gian (time-series) mô phỏng từ hệ thống SCADA của dây chuyền tiệt trùng UHT Tetra Pak / GEA:


- Tần suất lấy mẫu: 1 giây / mẫu.
- Các biến số: Thời gian (`timestamp`), Mã dây chuyền (`line_id`), Nhiệt độ gia nhiệt sơ bộ (`preheat_temp`), Nhiệt độ buồng tiệt trùng UHT (`uht_temp`), Áp suất đồng hóa giai đoạn 1 & 2 (`homo_press_stage1`, `homo_press_stage2`), Lưu lượng bơm (`flow_rate`), Độ dẫn điện vệ sinh CIP (`conductivity`), Mức tiêu thụ điện năng (`power_kw`).
- Quy mô: 10^6 – 10^7 bản ghi đại diện cho 180 ngày vận hành liên tục.
- **Nguồn 2 – Dữ liệu Nhật Ký Sản Xuất & Chất Lượng Lô Hàng (MES/LIMS Logs):**
 - Biến số: Mã lô (`batch_id`), Ngày sản xuất (`prod_date`), Mã loại sản phẩm (`sku_id`: Sữa tươi tiệt trùng nguyên chất, có đường, ít béo), Tỷ lệ béo đầu vào (`fat_in`), Tỷ lệ protein đầu vào (`protein_in`), Độ acid (`acidity_sh`), Tỷ lệ thu hồi chất khô (`yield_recovery_pct` – Biến liên tục mục tiêu), Trạng thái kiểm định vi sinh (`microbiology_status`), Nhãn lỗi lô hàng (`batch_defect_flag` $\in \{0, 1\}$ – Biến phân loại mục tiêu).
- **Nguồn 3 – Dữ liệu Crawl Thị Trường Sữa & Nông Sản Thế Giới (Web Crawled Market Data):**
 - *Nguồn cào 1:* Sàn giao dịch sữa toàn cầu **Global Dairy Trade (GDT)** (<https://www.globaldairytrade.info>) – Cào kết quả đấu giá định kỳ 2 tuần/lần đối với bột sữa nguyên kem (WMP), bột sữa gầy (SMP) và chất béo sữa khan (AMF).
 - *Nguồn cào 2:* Sàn giao dịch hàng hóa Chicago **CME Group Dairy Futures** (<https://www.cmegroup.com>) – Cào giá hợp đồng tương lai sữa Class III và bơ sữa hàng ngày.
 - *Nguồn cào 3:* Chỉ số giá lương thực thực phẩm thế giới **FAO Food Price Index** (<https://www.fao.org/worldfoodsituation/foodpricesindex>).
- **Nguồn 4 – Dữ liệu Crawl Khí Tượng Vùng Chăn Nuôi Cung Ứng (Crawled Farm Weather API):**
 - Thu thập qua API thời tiết lịch sử **Open-Meteo** (<https://archive-api.open-meteo.com>) đối với 5 tọa độ vùng trang trại bò sữa trọng điểm (Mộc Châu, Ba Vì, Nghệ An, Lâm Đồng, Củ Chi).
 - Các chỉ số: Nhiệt độ môi trường, Độ ẩm không khí tương đối, Lượng mưa, và tính toán chỉ số căng thẳng nhiệt ở bò sữa **THI (Temperature Humidity Index)**:
$$THI = (1.8 \times T + 32) - (0.55 - 0.0055 \times RH) \times (1.8 \times T - 26). \quad (1)$$

Khi $THI > 72$, bò sữa rơi vào trạng thái stress nhiệt, làm giảm nghiêm trọng hàm lượng protein và chất béo trong sữa tươi nguyên liệu giao đến nhà máy.
- **Nguồn 5 – Dữ liệu Cảnh Báo An Toàn & Thu Hồi Thực Phẩm (Food Safety Recalls Crawled Data):**
 - Thu thập từ cổng dữ liệu mở **US FDA Food Enforcement API** và bản tin cảnh báo từ Cục An toàn Thực phẩm (VFA) phục vụ giám sát rủi ro vi sinh học và dị vật bao bì.

3 Kiến Trúc Quản Trị Dữ Liệu Lớn (Data Lakehouse) & Hệ Thống Thu Thập

Để đáp ứng tối đa yêu cầu môn học về quản trị dữ liệu quy mô lớn và tốc độ truy vấn phân tích, nhóm thiết kế kiến trúc **Enterprise Smart Factory Lakehouse** dựa trên các công nghệ tiên tiến nhất: định dạng bảng giao dịch **ACID Delta Lake / Apache Iceberg** trên MinIO Object Storage, cụm cào phân tán **Scrapy/Playwright**, hệ sinh thái quản trị chất lượng **Great Expectations** và động cơ phân tích véc-tơ hóa nội tiến trình **chDB (ClickHouse C++ engine)** kết hợp **Polars**.

3.1 Sơ Đồ Kiến Trúc Smart Factory Data Lakehouse



Hình 2: Kiến trúc tổng thể Smart Factory Data Lakehouse với Delta Lake, chDB ClickHouse và cụm cào dữ liệu phân tán.

3.2 Các Điểm Đột Phá Về Mặt Kiến Trúc Dữ Liệu

- Cụm Thu Thập Dữ Liệu Đa Nguồn Phân Tán (Distributed Web Crawlers & Headless Engines):** Nhóm không dừng lại ở việc đọc tệp tĩnh mà xây dựng hệ thống cào dữ liệu công nghiệp hoàn chỉnh:
 - Sử dụng **Scrapy** kết hợp bộ quản lý luồng để cào dữ liệu dạng bảng từ Global Dairy Trade và FAO.
 - Sử dụng **Playwright / Headless Chromium** để kết xuất và vượt rào cản dynamic JavaScript rendering, cào dữ liệu hợp đồng tương lai tại CME Group.
 - Kỹ thuật **User-Agent Rotation**, **Exponential Backoff with Jitter** và **Token Bucket Rate Limiter** nhằm ngăn chặn tình trạng bị chặn IP (IP bans) và đảm bảo tính bền vững của luồng dữ liệu cào.
 - Tự động hóa lịch trình cào (Scheduled Crawling) và đẩy dữ liệu có gắn tem thời gian vào tầng Bronze Vault.
- Định dạng Bảng Giao Dịch ACID Delta Lake / Apache Iceberg trên MinIO Object Storage:** Khác với hồ dữ liệu (Data Lake) truyền thống dùng Parquet thô dễ bị lỗi khi ghi dữ liệu cảm biến đồng thời, tầng Curated sử dụng định dạng **Delta Lake** (deltalake-python):
 - Cung cấp tính toàn vẹn giao dịch ACID tuyệt đối thông qua nhật ký `_delta_log`.
 - Khả năng **Time-Travel**: Truy vấn lại trạng thái dữ liệu tại bất kỳ mốc thời gian hoặc phiên bản nào (`versionAsOf`), đáp ứng hoàn hảo tiêu chuẩn kiểm toán chất lượng an toàn thực phẩm ISO 22000 / HACCP khi cần điều tra lại lịch sử sản xuất của một lô hàng bị thu hồi.
 - Cơ chế **Schema Enforcement**: Tự động chặn đứng các bản ghi cảm biến có định dạng

sai lệch hoặc bị thiếu trường nghiêm trọng ngay tại thời điểm ghi.

3. **Quản Trị Hợp Đồng Dữ Liệu Công Nghiệp (Data Contracts) Với Great Expectations:** Mọi dữ liệu từ tầng Bronze sang Silver đều phải vượt qua bộ hợp đồng dữ liệu nghiêm ngặt được thiết lập bằng **Great Expectations (GX)**. Bộ quy tắc kiểm soát các ràng buộc vật lý và sinh học:

- Nhiệt độ UHT: $135.0^{\circ}\text{C} \leq T_{\text{uht}} \leq 145.0^{\circ}\text{C}$.
- Độ pH sữa nguyên liệu: $6.4 \leq \text{pH} \leq 6.8$.
- Tỷ lệ khuyết thiếu của cảm biến quan trọng $\leq 1\%$.
- Hệ thống tự động xuất bản báo cáo trực quan ****Data Docs HTML**** minh bạch hóa độ sạch của dữ liệu.

4. **Động Cơ Phân Tích OLAP Nội Tiến Trình chDB (ClickHouse C++ SIMD Vectorized Engine):** Nhóm sử dụng **chDB** – phiên bản in-process C++ nhúng của hệ quản trị dữ liệu phân tích số một thể giới ****ClickHouse****.

- Vận hành trực tiếp trên các bảng Delta Lake / Parquet mà không cần qua khâu sao chép trung gian (Zero-Copy Data Sharing qua Apache Arrow).
- Tận dụng tối đa tập lệnh SIMD (AVX2 / AVX-512) để thực hiện quét bảng và tính toán các chỉ số thống kê công nghiệp (avg, stddevSamp, quantileTDigest, corr) trên hàng chục triệu dòng dữ liệu cảm biến chỉ trong dưới 100 ms.

5. **Khung Xử Lý Đa Luồng Polars (Rust-based Fast Data Manipulation):** Thay thế hoàn toàn Pandas đơn luồng chậm chạp, nhóm áp dụng thư viện **Polars** với cơ chế thực thi lười (Lazy Execution), tối ưu hóa kế hoạch truy vấn (Query Plan Optimization) và tận dụng 100% các lõi CPU của máy chủ để tiền xử lý và tổng hợp dữ liệu.

3.3 Thiết Kế Mô Hình Kho Dữ Liệu Nhà Máy (Industrial Star Schema)

Cơ sở dữ liệu phân tích tập trung `factory_analytics.chdb` được thiết kế theo mô hình hình sao (Star Schema) chuẩn Kimball:

- **Bảng Chiều Thiết Bị & Dây Chuyền (dim_equipment):**
equipment_id (PK), equipment_code, equipment_type (Pasteurizer, Homogenizer, Filler), line_id, manufacturer, installation_date, design_capacity_lph.
- **Bảng Chiều Sản Phẩm SKU (dim_product_sku):**
sku_id (PK), product_name, packaging_type (Tetra Brik 220ml, Tetra Prisma 1L), target_fat_pct, target_protein_pct, shelf_life_days.
- **Bảng Chiều Trang Trại Cung Ứng Sữa (dim_farm_supplier):**
farm_id (PK), farm_name, region, latitude, longitude, herd_size, certifications (GlobalGAP, Organic).
- **Bảng Fact Nhật Ký Đo Lường Cảm Biến (fact_sensor_telemetry):**
telemetry_id (PK), timestamp, equipment_id (FK), batch_id (FK), metric_temperature, metric_pressure, metric_flow_rate, metric_power, is_anomaly_flag. Phân vùng theo tháng (PARTITION BY toYYYYMM(timestamp)).
- **Bảng Fact Lô Hàng Sản Xuất (fact_batch_production):**
batch_id (PK), prod_date, sku_id (FK), line_id (FK), farm_id (FK), raw_milk_volume_l, yield_recovery_pct, defect_flag, cycle_time_hours, energy_kwh_per_ton.
- **Bảng Fact Thị Trường & Khí Hậu Cào Phân Tán (fact_external_market_weather):**
record_id (PK), date, gdt_wmp_price_usd, cme_milk_future_usd, farm_id (FK), ambient_temp,

ambient_humidity, thi_index.

3.4 Cấu Trúc Cây Thư Mục Dự Án (Repository Structure)

```
smart-dairy-lakehouse-it5425/
|-- data/
|   |-- 01_bronze_vault/           # Raw landed JSON/Parquet dumps & crawler
|       landing
|   |-- 02_silver_curated/        # Clean Delta Lake ACID tables & Great
|       Expectations
|   +-- 03_gold_marts/           # Star Schema analytical store (chDB / Parquet)
|-- src/
|   |-- 01_lakehouse_storage/     # P1: Delta Lake, MinIO, ACID Transaction (TV 1
|       - Lead)
|   |-- 02_crawling_ingestion/    # P2: Scrapy cluster, Playwright, Market &
|       Weather (TV 2)
|   |-- 03_data_governance/      # P3: Great Expectations Data Docs & Lineage (TV
|       3)
|   |-- 04_olap_engineering/     # P4: chDB ClickHouse Engine, Polars & Star
|       Schema (TV 4)
|   |-- 05_manufacturing_spc/    # P5: Industrial EDA, SPC Shewhart, CUSUM & Cp/
|       Cpk (TV 5)
|   |-- 06_statistical_models/   # P6: Linear & Logistic Regression, MLE & EM
|       Algo (TV 6)
|   +-- 07_industrial_dash_ui/   # P7: Plotly Dash Production Center & What-If
|       Sim (TV 7)
|-- crawlers/                   # Scrapy spiders & Playwright headless scripts
|   |-- gdt_spider.py            # Global Dairy Trade auction prices
|   |-- cme_futures_crawler.py   # CME Group milk & dairy futures
|   +-- open_meteo_client.py     # Weather API & THI calculator
|-- reports/                    # Comprehensive LaTeX Report & PDF
|-- slides/                    # Master Presentation Deck (LaTeX Beamer)
|-- tests/                     # Pytest suite for pipelines, contracts & models
|-- pyproject.toml / requirements.txt
+-- README.md                  # Reproduction guide & Architecture
    specifications
```

4 Ma Trận Phân Công 07 Hợp Phần Chuyên Môn Cho 07 Thành Viên

4.1 Bảng Tổng Hợp Trách Nhiệm & Tỷ Lệ Đóng Góp (07 Thành Viên)

4.2 Đặc Tả Chi Tiết Từng Phân Hệ Kỹ Thuật (P1 → P7)

4.2.1 Phân Hệ 1: Enterprise Data Lakehouse Architecture, Delta Lake ACID & Storage Engine

Người phụ trách: Thành viên 1 (TV 1 – Nhóm trưởng / Lakehouse Storage Lead)

Tiến độ bàn giao: Sprint 1 (Ưu tiên số một, thiết lập nền móng hạ tầng lưu trữ cho toàn nhóm).

- **Ràng buộc đầu vào & đầu ra:**

- *Đầu vào:* Dữ liệu cảm biến streaming và batch logs công nghiệp dạng raw từ các cổng tiếp nhận.
- *Đầu ra:* Hệ thống lưu trữ Delta Lake ACID hoàn chỉnh tại `data/02_silver_curated/`, module quản trị bằng `lakehouse_manager.py`, nhật ký giao dịch `_delta_log`, kịch bản Time-Travel audit trails đáp ứng chuẩn ISO 22000 / HACCP.

- **Cơ sở lý thuyết & Toán học:**

Bảng 1: Ma trận phân công 07 phân hệ kỹ thuật độc lập cho 07 thành viên (Tổng 100%).

STT	Thành viên	Phân hệ chuyên môn kỹ thuật phụ trách	Phạm vi báo cáo	% Đóng góp
1	TV 1 (Trưởng nhóm)	Phần 1: Enterprise Data Lakehouse Architecture, Delta Lake ACID & Storage Engine	Chương 1 & Mục 2.1	14.3%
2	TV 2	Phần 2: Distributed Web Crawling, Playwright Scraping & Multi-source Ingestion	Mục 2.2 & Chương 3	14.3%
3	TV 3	Phần 3: Industrial Data Governance, Great Expectations Data Contracts & Data Lineage	Mục 2.3	14.3%
4	TV 4	Phần 4: Analytical Data Marts (Star Schema), Polars Pipeline & chDB ClickHouse Engine	Chương 4	14.3%
5	TV 5	Phần 5: Manufacturing EDA, Statistical Process Control (SPC) & Capability (C_p, C_{pk})	Chương 5	14.3%
6	TV 6	Phần 6: Applied Statistical Linear Modeling: Linear/Logistic, MLE & EM Algorithm	Chương 6	14.3%
7	TV 7	Phần 7: Industrial Visual Analytics Dashboard (Plotly Dash), What-If Simulator & Storytelling	Chương 7 & Tổng hợp	14.2%
Toàn bộ nhóm (07 TV)		Giải pháp Quản trị Dữ liệu Lớn & Trực quan hóa Nhà máy Thông minh	Toàn văn Báo cáo	100.0%

- Lý thuyết lưu trữ cột (Columnar Storage) và các thuật toán nén hiện đại: Snappy, Zstandard, Dictionary Encoding, Run-Length Encoding (RLE) và Bit-packing.
- Nguyên lý giao dịch ACID (Atomicity, Consistency, Isolation, Durability) trên Object Storage không trạng thái; cơ chế kiểm soát tương tranh lạc quan (Optimistic Concurrency Control – OCC).
- Cơ chế *Z-Ordering Clustering* trên không gian dữ liệu đa chiều để tối ưu hóa việc bỏ qua khối dữ liệu không liên quan (Data Skipping via Min/Max statistics):

$$\text{Z-Value}(x_1, x_2) = \text{InterleaveBits}(x_1, x_2). \quad (2)$$

- Mô hình toán học về I/O Footprint và chi phí quét dữ liệu giữa Row-oriented storage ($\mathcal{O}(N \times D)$) so với Columnar storage có partition pruning ($\mathcal{O}(N_{\text{active}} \times d_{\text{query}})$ với $d_{\text{query}} \ll D$).

• Lập trình & Kỹ thuật:

- Cấu hình cụm lưu trữ MinIO S3-compatible cục bộ và tích hợp thư viện **deltalake** (Rust-based core).
- Xây dựng pipeline tự động phân vùng bảng **fact_sensor_telemetry** theo ngày (**date**) và mã dây chuyền (**line_id**).
- Lập trình các hàm quản trị bảng Delta Lake: **vacuum()** dọn dẹp các tệp mồ côi (tombstones), **optimize()** nén các tệp nhỏ (Compaction nhỏ hơn 128MB) để loại bỏ vấn đề Small File Problem trong Big Data.
- Xây dựng kịch bản tái lập dữ liệu theo thời gian thực (Time-Travel query) phục vụ truy vết lỗi: **dt.load_version(v)** hoặc **dt.load_as_of(timestamp)**.
- **Thực quan hóa chuẩn mực:** Sơ đồ kiến trúc phân tầng lưu trữ Medallion Architecture; Biểu đồ Bar Chart so sánh dung lượng đĩa cứng và thời gian I/O giữa CSV, Parquet thường và Delta Lake nén Zstd.
- **Nội dung Báo cáo & Slide:** Chương 1 (Bối cảnh dự án) và Mục 2.1 (Kiến trúc Enterprise Data Lakehouse, Cơ chế Delta Lake ACID, Z-Order & Tiêu chuẩn Kiểm toán ISO 22000).

4.2.2 Phân Hệ 2: Distributed Web Crawling, Playwright Scraping & Multi-source Ingestion

Người phụ trách: Thành viên 2 (TV 2 – Ingestion & Web Crawling Lead)

Tiến độ bàn giao: Sprint 1 & Sprint 2.

• Ràng buộc đầu vào & đầu ra:

- **Đầu vào:** Các URL mục tiêu: Global Dairy Trade (GDT), CME Group Dairy Futures, FAO Food Price Index, Open-Meteo Historical Weather API, và FDA Recalls.
- **Đầu ra:** Cụm script cào dữ liệu tự động hóa (**crawlers/**), tập tệp raw JSON/Parquet có gắn nhãn nguồn gốc và mã băm kiểm toán SHA-256 lưu trữ tại **data/01_bronze_vault/**.

• Cơ sở lý thuyết & Toán học:

- Lý thuyết thu thập dữ liệu web phân tán (Distributed Web Crawling Architecture): Kiến trúc Spider-Downloader-Pipeline.
- Thuật toán điều tiết lưu lượng (Rate-Limiting) bằng thuật toán Xô chứa thẻ bài (**Token Bucket Algorithm**):

$$B(t) = \min(C, B(t_0) + r \cdot (t - t_0)), \quad (3)$$

trong đó C là dung lượng tối đa của xô, r là tốc độ nạp xô (tokens/second).

- Thuật toán chờ lùi theo cấp số nhân có nhiều ngẫu nhiên (**Exponential Backoff with Jitter**) để xử lý khi gặp mã phản hồi HTTP 429 / 503:

$$t_{\text{wait}} = \text{Uniform} \left(0, \min(t_{\text{max}}, t_{\text{base}} \times 2^{\text{attempt}}) \right). \quad (4)$$

- Phân tích cấu trúc DOM, XPath/CSS Selector tối ưu, và cơ chế vượt tường chắn kiểm tra bot (Cloudflare, Akamai fingerprint spoofing) bằng cách điều chỉnh Header Navigator.

- **Lập trình & Kỹ thuật:**

- Xây dựng dự án **Scrapy** chuyên dụng cào bảng kết quả đấu giá lịch sử từ Global Dairy Trade (bột sữa WMP, SMP, AMF).
- Lập trình kịch bản **Playwright headless browser** (Chromium) tự động điều khiển cuộn trang, xử lý sự kiện JavaScript bất đồng bộ để cào dữ liệu tương lai CME Dairy Futures.
- Tích hợp REST API client kết nối Open-Meteo API lấy dữ liệu nhiệt độ, độ ẩm tại 5 vùng chăn nuôi bò sữa, tự động tính toán chỉ số THI.
- Xây dựng cơ chế phát hiện dữ liệu cào trùng lặp (Deduplication) bằng Fingerprint Hashing.

- **Trực quan hóa chuẩn mực:** Sơ đồ luồng thu thập dữ liệu phân tán (Web Scraping Pipeline Architecture); Biểu đồ phân tích độ trễ cào dữ liệu và tỷ lệ thành công theo thời gian (Scraping Throughput & Success Rate).

- **Nội dung Báo cáo & Slide:** Mục 2.2 & Chương 3 (Hệ thống Thu thập Dữ liệu Lớn Đa Nguồn: Kỹ thuật Crawling Phân tán, Vượt Rào cản Bot & Cơ chế Ingestion vào Bronze Vault).

4.2.3 Phân Hệ 3: Industrial Data Governance, Great Expectations Data Contracts & Data Lineage

Người phụ trách: Thành viên 3 (TV 3 – Data Governance & Quality Lead)

Tiến độ bàn giao: Sprint 2.

- **Ràng buộc đầu vào & đầu ra:**

- *Đầu vào:* Dữ liệu thô từ tầng Bronze (do TV 1 & TV 2 nạp vào).
- *Đầu ra:* Bộ Hợp đồng Dữ liệu (*Data Contracts Expectation Suites*), Báo cáo trực quan tương tác **Data Docs HTML**, biểu đồ phả hệ nguồn gốc dữ liệu (**Data Lineage Graph**), và bộ dữ liệu sạch đạt chuẩn kiểm định (*Validated Silver Tables*).

- **Cơ sở lý thuyết & Toán học:**

- Khung quản trị chất lượng dữ liệu quốc tế theo DAMA-DMBOK và ISO 8000 với 6 chiều cốt lõi: Tính đầy đủ (Completeness), Tính hợp lệ (Validity), Tính chính xác (Accuracy), Tính nhất quán (Consistency), Tính duy nhất (Uniqueness) và Tính kịp thời (Timeliness).
- Lý thuyết phát hiện ngoại lai chuỗi thời gian cảm biến công nghiệp:
 - * Bộ lọc Hampel (Hampel Filter) dựa trên độ lệch tuyệt đối trung vị (Median Absolute Deviation – MAD):

$$\text{MAD}_t = 1.4826 \times \text{median}(|x_{t-k} \dots x_{t+k} - \tilde{x}_t|), \quad \text{Outlier if } |x_t - \tilde{x}_t| > 3 \times \text{MAD}_t. \quad (5)$$

- * Rolling Z-score thích ứng với cửa sổ trượt (Adaptive Rolling Window).

- Mô hình toán học về đồ thị có hướng không chu trình (Directed Acyclic Graph – DAG) biểu diễn phả hệ dữ liệu từ nguồn cào/cảm biến qua các tầng biến đổi đến báo cáo cuối cùng.
- **Lập trình & Kỹ thuật:**
 - Cấu hình và lập trình thư viện **Great Expectations (GX)** phiên bản mới: định nghĩa các bộ kỳ vọng nghiêm ngặt cho cảm biến UHT (nhiệt độ, áp suất, độ acid) và dữ liệu cào thị trường.
 - Xây dựng cơ chế chốt chặn tự động (Fail-Fast Data Gatekeeper): Nếu tỷ lệ bản ghi lỗi vượt quá 0.5%, pipeline lập tức dừng và gửi cảnh báo, không cho phép dữ liệu bản lọt vào tầng Silver.
 - Tích hợp tự động xuất bản tài liệu **Data Docs HTML** cập nhật sau mỗi đợt nạp dữ liệu.
 - Thiết lập **OpenLineage / Marquez** để tự động theo dõi metadata và vẽ đồ thị phả hệ dữ liệu từng bước xử lý.
- **Trực quan hóa chuẩn mực:** Bản đồ nhiệt độ khuyết thiếu dữ liệu (Missingness Matrix Heatmap); Biểu đồ dải giới hạn sinh hóa và ngoại lai cảm biến (Sensor Physical Bands & Hampel Outliers Plot); Sơ đồ mạng lưới Data Lineage DAG.
- **Nội dung Báo cáo & Slide:** Mục 2.3 (Quản trị Dữ liệu Công nghiệp, Khung Great Expectations, Data Lineage & Giám sát Chất lượng Dữ liệu Dây chuyền Sữa).

4.2.4 Phân Hệ 4: Analytical Data Marts (Star Schema), Polars Pipeline & chDB ClickHouse Engine

Người phụ trách: Thành viên 4 (TV 4 – Analytical Engineering & OLAP Lead)

Tiến độ bàn giao: Sprint 2 & Sprint 3.

- **Ràng buộc đầu vào & đầu ra:**
 - *Đầu vào:* Dữ liệu sạch tầng Silver từ TV 1 & TV 3.
 - *Đầu ra:* Tập cơ sở dữ liệu phân tích tập trung **factory_analytics.chdb**, các bảng Data Marts tối ưu hóa (Star Schema), module kết nối SQL tốc độ cao **chdb_analytics_engine.py**, và bộ kiểm chuẩn hiệu năng truy vấn (Query Benchmark Report).
- **Cơ sở lý thuyết & Toán học:**
 - Phương pháp luận mô hình hóa dữ liệu chiều (Dimensional Modeling) của Ralph Kimball: Fact Tables (Additive, Semi-additive) và Dimension Tables (SCD Type 1/Type 2).
 - Nguyên lý Vectorized Execution của động cơ ClickHouse C++ trên thanh ghi SIMD (Single Instruction Multiple Data): Xử lý đồng thời mảng 256-bit / 512-bit, triệt tiêu chi phí Overhead của Virtual Function Calls.
 - Cấu trúc dữ liệu cây MergeTree và cơ chế chỉ mục thưa (Sparse Indexing) với Primary Key và Index Granularity (8192 dòng/khối).
 - Mô hình toán học về độ phức tạp nén dữ liệu và chi phí truy vấn tổng hợp đa chiều (Aggregation over billions of records).
- **Lập trình & Kỹ thuật:**
 - Lập trình quy trình ETL/ELT chuyển đổi dữ liệu tầng Silver sang Star Schema bằng **Polars LazyFrame** (tối ưu hóa bộ lọc Predicate Pushdown và Projection Pushdown).
 - Xây dựng cơ sở dữ liệu **chDB (in-process ClickHouse)** nhúng trực tiếp trong Python:

Tạo bảng **MergeTree**, bảng tổng hợp trước **AggregatingMergeTree** cho các chỉ số cảm biến theo phút/giờ.

- Viết các truy vấn SQL phân tích phức tạp sử dụng các hàm tối ưu riêng của ClickHouse: `quantileTDigest(0.95)(temp)`, `corr(uht_temp, yield)`, `groupArray()`, `windowFun()`.
- Viết kịch bản benchmark độc lập đo thời gian truy vấn và RAM đỉnh (Peak Memory) giữa: Pandas, SQLite, DuckDB và giải pháp chDB trên tập dữ liệu 5×10^6 dòng cảm biến.
- **Trực quan hóa chuẩn mực:** Sơ đồ quan hệ thực thể Star Schema (ERD Diagram); Biểu đồ Benchmark hiệu năng (Latency vs Data Size log-scale, RAM Consumption Bar Chart).
- **Nội dung Báo cáo & Slide:** Chương 4 (Mô hình Hóa Kho Dữ liệu Nhà máy Thông minh, Tối ưu Hóa Polars Pipeline & Động Cơ Phân Tích OLAP chDB ClickHouse).

4.2.5 Phân Hệ 5: Manufacturing EDA, Statistical Process Control (SPC) & Capability (C_p, C_{pk})

Người phụ trách: Thành viên 5 (TV 5 – Manufacturing EDA & SPC Lead)

Tiến độ bàn giao: Sprint 3.

- **Ràng buộc đầu vào & đầu ra:**

- *Đầu vào:* Các bảng Data Marts từ chDB do TV 4 cung cấp.
- *Đầu ra:* Bảng phân tích đặc trưng khám phá (Manufacturing EDA Summary), bộ tham số giới hạn kiểm soát SPC (UCL, LCL, CL), các chỉ số năng lực dây chuyền (C_p, C_{pk}, C_{pm}), nhật ký vi phạm quy tắc Nelson Rules, và ma trận tương quan sàng lọc biến chuyển giao cho TV 6 và TV 7.

- **Cơ sở lý thuyết & Toán học:**

- Lý thuyết Kiểm soát Quá trình Thống kê (**Statistical Process Control – SPC**):
 - * Biểu đồ kiểm soát Shewhart ($\bar{X} - R$ và $\bar{X} - S$ charts) cho biến số liên tục (Nhiệt độ UHT, Áp suất đồng hóa):

$$UCL_{\bar{X}} = \bar{\bar{X}} + A_2 \bar{R}, \quad CL_{\bar{X}} = \bar{\bar{X}}, \quad LCL_{\bar{X}} = \bar{\bar{X}} - A_2 \bar{R}. \quad (6)$$

- * Biểu đồ Tổng tích lũy (**CUSUM Chart**) và Trung bình trượt trọng số hàm mũ (**EWMA Chart**) có độ nhạy cực cao trong việc phát hiện các độ lệch nhỏ ($\Delta\mu \in [0.5\sigma, 1.5\sigma]$) của nhiệt độ tiệt trùng:

$$Z_i = \lambda X_i + (1 - \lambda)Z_{i-1}, \quad \lambda \in (0, 1]. \quad (7)$$

- Các quy tắc phát hiện bất thường nâng cao (**Nelson Rules / Western Electric Rules**): 8 quy tắc nhận diện dây chuyền mất kiểm soát thống kê.
- Chỉ số năng lực quy trình công nghiệp (**Process Capability Indices**):

$$C_p = \frac{USL - LSL}{6\sigma}, \quad C_{pk} = \min\left(\frac{USL - \mu}{3\sigma}, \frac{\mu - LSL}{3\sigma}\right). \quad (8)$$

Yêu cầu dây chuyền đạt chuẩn khi $C_{pk} \geq 1.33$ (hoặc 4 Sigma).

- Phân tích ma trận tương quan Spearman / Pearson và kiểm định đa cộng tuyến (Variance Inflation Factor – VIF) nhằm sàng lọc đặc trưng sạch cho mô hình hồi quy.
- **Lập trình & Kỹ thuật:**

- Viết module tính toán tự động các đường biên kiểm soát SPC (UCL, LCL) và tự động gắn cờ 8 quy tắc Nelson trên luồng dữ liệu chuỗi thời gian.
- Lập trình hàm tính toán C_p, C_{pk} tự động đối chiếu với tiêu chuẩn giới hạn kỹ thuật (USL/LSL) của nhà máy sữa.
- Phân tích tương quan giữa dữ liệu thời tiết nông trại cào được (THI) với hàm lượng chất béo đầu vào và tỷ lệ thu hồi sản phẩm.
- **Trực quan hóa chuẩn mực:** Biểu đồ kiểm soát chất lượng Shewhart $\bar{X} - S$ và CUSUM kèm điểm đánh dấu vi phạm Nelson Rules; Biểu đồ phân phối năng lực quy trình (Process Capability Histogram đối chiếu USL/LSL); Heatmap ma trận tương quan kèm mức ý nghĩa thống kê (p -value).
- **Nội dung Báo cáo & Slide:** Chương 5 (Khám Phá Dữ Liệu Sản Xuất, Kiểm Soát Quá Trình Thống Kê SPC & Đánh Giá Năng Lực Dây Chuyền Nhà Máy).

4.2.6 Phân Hệ 6: Applied Statistical Linear Modeling: Linear/Logistic, MLE & EM Algorithm

Người phụ trách: Thành viên 6 (TV 6 – Applied Statistical Modeling Lead)

Tiến độ bàn giao: Sprint 3 & Sprint 4.

- **Ràng buộc đầu vào & đầu ra:**

- *Đầu vào:* Tập biến đặc trưng đã qua tiền xử lý, kiểm tra cộng tuyến từ TV 5 và dữ liệu Star Schema sạch từ TV 4.
- *Đầu ra:* Mô hình Hồi quy tuyến tính dự báo tỷ lệ thu hồi chất khô (`yield_model.pkl`), Mô hình Hồi quy Logistic dự báo xác suất lỗi lô (`defect_risk_model.pkl`), giải thuật EM xử lý dữ liệu cảm biến khuyết thiếu/biến ẩn, bộ tham số trọng số (β), và báo cáo kiểm định độ phù hợp (Goodness-of-fit, ROC-AUC) bàn giao cho TV 7 tích hợp vào Simulator.

- **Cơ sở lý thuyết & Toán học:**

- **Mô hình Hồi quy Tuyến tính Đa biến (Multiple Linear Regression) có Điều chuẩn:** Dự báo tỷ lệ thu hồi chất khô (`yield_recovery_pct`) dựa trên các thông số công nghệ:

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma^2). \quad (9)$$

Áp dụng điều chuẩn ElasticNet (kết hợp Lasso L_1 để loại bỏ biến thừa và Ridge L_2 để ổn định ước lượng khi các cảm biến nhiệt độ/áp suất có tính tương quan):

$$\hat{\beta} = \arg \min_{\beta} \left\{ \frac{1}{2n} \sum_{i=1}^n (y_i - \beta_0 - \mathbf{x}_i^T \beta)^2 + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right) \right\}. \quad (10)$$

- **Mô hình Hồi quy Logistic & Ước lượng Hợp lý Cực đại (MLE):** Dự báo xác suất lô hàng bị lỗi vi sinh/kết tủa ($Y_i = 1$):

$$p_i = \mathbb{P}(Y_i = 1 \mid \mathbf{x}_i) = \frac{1}{1 + \exp(-(\beta_0 + \mathbf{x}_i^T \beta))}. \quad (11)$$

Hàm Log-Likelihood:

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)]. \quad (12)$$

Tối ưu hóa bằng thuật toán lặp bình phương tối thiểu có trọng số (Iteratively Reweighted Least Squares – IRLS / Newton-Raphson).

– **Thuật toán Kỳ Vọng – Cực Đại hóa (EM Algorithm):** Ứng dụng giải quyết hai bài toán kinh điển trong quản trị dữ liệu nhà máy:

1. *Xử lý dữ liệu cảm biến đo lường bị khuyết thiếu ngẫu nhiên (Missing at Random – MAR):* Dữ liệu quan sát $\mathbf{X}_{\text{obs}}$, dữ liệu khuyết $\mathbf{X}_{\text{mis}}$.
2. *Phân cụm trạng thái ẩn của dây chuyền (Latent Operational Regimes):* Biến ẩn $Z_i \in \{1, \dots, K\}$ đại diện cho trạng thái máy (Vận hành chuẩn, Bắt đầu đóng cặn nhiệt/Fouling, hoặc Rung lắc mòn van).

Hai bước cốt lõi của giải thuật EM:

$$\text{E-step: } Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(t)}) = \mathbb{E}_{\mathbf{X} \mid \boldsymbol{\theta}^{(t)}} [\ln L(\boldsymbol{\theta}; \mathbf{X})], \quad (13)$$

$$\text{M-step: } \boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(t)}). \quad (14)$$

– **Ước Lượng Hợp Lý Cực Đại Phi Tham Số (NPMLE):** Ứng dụng ước lượng hàm độ tin cậy và phân phối thời gian hoạt động liên tục trước khi hỏng hóc của van áp suất đồng hóa (Survival / Reliability NPMLE Kaplan–Meier analysis).

– **Đánh giá độ phù hợp mô hình (Model Goodness-of-Fit):** R^2 , Adjusted R^2 , AIC, BIC, Hosmer–Lemeshow test, và đường cong ROC/PR với chỉ số tối ưu Youden’s J .

• **Lập trình & Kỹ thuật:**

- Huấn luyện mô hình Hồi quy đa biến và Hồi quy Logistic bằng `statsmodels` để trích xuất đầy đủ p -value, khoảng tin cậy 95% và tỷ số chênh Odds Ratio ($e^{\hat{\beta}_j}$).
- Tự lập trình giải thuật EM bằng Python thuần kết hợp NumPy để ước lượng các tham số phân phối khi có dữ liệu cảm biến khuyết thiếu và phân tách trạng thái ẩn của dây chuyền.
- Đóng gói mô hình thành chuẩn Serializable (ONNX / Joblib) cho phép TV 7 nhúng trực tiếp vào bộ mô phỏng trên giao diện web.

• **Trực quan hóa chuẩn mực:** Đồ thị Residuals vs Fitted Plot kiểm tra tính đồng phương sai; Biểu đồ Coefficient Shrinkage Path của ElasticNet; Đường cong hội tụ Log-Likelihood của thuật toán EM; Đồ thị ROC Curve kèm diện tích AUC và điểm cắt tối ưu Youden’s J .

• **Nội dung Báo cáo & Slide:** Chương 6 (Mô hình Hóa Thống Kê Tuyến Tính Ứng Dụng Trong Nhà Máy: Hồi Quy Tuyến Tính, Hồi Quy Logistic, Ước Lượng MLE, Thuật Toán EM & Đánh Giá Độ Phù Hợp).

4.2.7 Phân Hệ 7: Industrial Visual Analytics Dashboard (Plotly Dash), What-If Simulator & Storytelling

Người phụ trách: Thành viên 7 (TV 7 – Dashboard Lead & Visual Analytics Lead)

Tiến độ bàn giao: Sprint 4 & Sprint 5 (Chủ trì tích hợp toàn diện hệ thống).

• **Ràng buộc đầu vào & đầu ra:**

- *Đầu vào:* Kết nối chDB SQL từ TV 4, Dữ liệu cào thị trường/thời tiết từ TV 2, Báo cáo Data Docs từ TV 3, Biểu đồ kiểm soát SPC từ TV 5, và Mô hình dự báo từ TV 6.
- *Đầu ra:* Ứng dụng Web hoàn chỉnh **Smart Dairy Industrial Analytics Platform** (Plotly Dash), Bộ mô phỏng tham số **What-If Quality Simulator**, Master Slide thuyết trình thống nhất và tổng biên tập bản báo cáo toàn diện của nhóm.

- **Cơ sở lý thuyết & Toán học:**

- Các nguyên lý thiết kế giao diện trực quan hóa công nghiệp chuẩn mực (Claus Wilke, Edward Tufte, Stephen Few): Tối ưu hóa tỷ lệ Data-to-Ink, giảm thiểu tải nhận thức (Cognitive Load) cho kỹ sư vận hành nhà máy.
- Kiến trúc phản ứng hướng sự kiện (**Reactive Callbacks Architecture**):

$$f : (\text{Inputs, States}) \xrightarrow{\text{Event-Triggered}} \text{Outputs (DOM / Figures)}, \quad (15)$$

kết hợp kỹ thuật Client-side Caching (`dcc.Store`) và Memoization nhằm đạt tốc độ phản hồi < 50 ms.

- Khung kể chuyện dữ liệu công nghiệp (**Industrial Data Storytelling**): Cấu trúc kịch bản 3 hồi dẫn dắt từ tổng quan hiệu suất nhà máy (OEE) → Phát hiện bất thường cảm biến (SPC) → Can thiệp dự báo và tối ưu hóa thông số bằng What-If Simulator.

- **Lập trình & Kỹ thuật:**

- Xây dựng ứng dụng Web bằng **Plotly Dash** kết hợp thư viện giao diện hiện đại **Dash Bootstrap Components (dbc)**:


- * *Tab 1: Executive Operations & OEE Overview*: Thẻ chỉ số KPI (Hiệu suất tổng thể thiết bị OEE, Sản lượng ngày, Tỷ lệ đạt chuẩn FTT), biểu đồ xu hướng vận hành.
- * *Tab 2: Real-time SPC & Sensor Telemetry*: Biểu đồ Shewhart $\bar{X} - S$ tương tác, thanh quét thời gian, tự động tô màu cảnh báo vi phạm Nelson Rules trên tháp UHT.
- * *Tab 3: External Market & Weather Surveillance*: Bản đồ tương tác hiển thị vị trí các nông trại cung cấp sữa, chỉ số căng thẳng nhiệt THI, và biểu đồ giá sữa thế giới cào được từ sàn GDT/CME.
- * *Tab 4: Interactive What-If Quality Simulator*: Bảng điều khiển cho phép kỹ sư kéo thanh trượt điều chỉnh nhiệt độ UHT, áp suất đồng hóa, chất lượng sữa thô đầu vào → Hệ thống tính toán véc-tơ hóa nội bộ trong RAM và cập nhật tức thì tỷ lệ thu hồi dự báo kèm xác suất lỗi lô hàng.

- Tối ưu hóa hiệu năng giao diện: Sử dụng WebGL (`scattergl`) để vẽ trơn tru các biểu đồ cảm biến hàng chục nghìn điểm đo mà không bị giật lag trình duyệt.

- **Trực quan hóa chuẩn mực**: Giao diện Dashboard chuẩn phong cách phòng điều hành trung tâm (Industrial Scada-like Dark/Light Theme); Thước đo rủi ro Gauge Charts; Bản đồ tương tác Plotly Mapbox thể hiện các trang trại cung ứng; Bộ thanh trượt What-If Sliders tương tác thời gian thực.
- **Nội dung Báo cáo & Slide**: Chương 7 (Kiến Trúc Nền Tảng Trực Quan Hóa Giám Sát Dây chuyền Nhà Máy Thông Minh Plotly Dash, Tối Ưu Hiệu Năng Phản Ứng & Bộ Mô Phỏng What-If); Chủ trì rà soát và đóng gói báo cáo cuối kỳ.

5 Sơ Đồ Chuyển Giao & Mạng Lưới Quan Hệ Tiên Quyết Giữa 07 Thành Viên

Mối quan hệ phối hợp và luồng chuyển giao sản phẩm trung gian giữa 07 thành viên được chuẩn hóa theo sơ đồ mạng lưới công việc dưới đây:



Hình 3: Sơ đồ mạng lưới chuyển giao sản phẩm trung gian khép kín giữa 07 thành viên.

6 Lộ Trình Triển Khai Chi Tiết (06 Sprints / 15 Tuần)

Tiến độ dự án được quản trị nghiêm ngặt theo mô hình Agile/Scrum với 06 Sprints trải dài trong 15 tuần học kỳ, phân định rõ trách nhiệm cho 07 thành viên:

7 Quy Chuẩn Đồ Họa & Trực Quan Hóa Dữ Liệu Công Nghiệp

Nhằm đáp ứng yêu cầu khắt khe về tính chuyên nghiệp và thẩm mỹ khoa học trong trực quan hóa dữ liệu công nghiệp (dựa trên nguyên tắc của Claus Wilke, Edward Tufte và Stephen Few), nhóm tuân thủ triệt để các tiêu chí sau:

1. Quy chuẩn Bảng Màu Công Nghiệp (Industrial Color Palette):

- Sử dụng màu xanh thép công nghiệp (#184C78) làm màu nhận diện chủ đạo cho các trạng thái vận hành bình thường và các đường chuẩn trung tâm.
- Các trạng thái cảnh báo lệch chuẩn (Warnings) sử dụng màu hổ phách (#D97706); trạng thái vi phạm tới hạn hoặc lỗi lô hàng bắt buộc dừng màu đỏ báo động (#D9534F).
- Tuyệt đối không lạm dụng các màu sắc sặc sỡ không có ý nghĩa thông tin; loại bỏ triệt để bảng màu cầu vồng (Rainbow / Jet palette).

2. Tối Ưu Hóa Tỷ Lệ Data-to-Ink (Edward Tufte):

- Loại bỏ các đường kẻ khung viền hộp nặng nề, loại bỏ lưới nền đậm màu; chỉ giữ lại các đường giống ngang nhạt tại các mức kiểm soát tới hạn (UCL, LCL, $\bar{X}$).
- Sử dụng kỹ thuật **Gán nhãn trực tiếp (Direct Labeling)** ngay tại điểm cuối của các đường biểu diễn thay vì bắt người xem tra cứu hộp chú giải (legend) ở góc xa.

3. Trực Quan Hóa Sự Không Chắc Chắn (Visualizing Uncertainty):

- Mọi đường dự báo hồi quy trong What-If Simulator hoặc đường xu hướng chuỗi thời gian cảm biến **bắt buộc phải đi kèm dải bóng mờ biểu diễn khoảng tin cậy 95% (95% Confidence Bands)**.

Bảng 2: Kế hoạch tiến độ triển khai 15 tuần của dự án IT5425 cho 07 thành viên.

Sprint	Thời gian	Mục tiêu trọng tâm & Phân công công việc	Sản phẩm bàn giao
Sprint 1	Tuần 1 – Tuần 3	TV 1 thiết lập cụm MinIO và hạ tầng Delta Lakehouse; TV 2 phát triển cụm cào Scrapy và Playwright cào dữ liệu GDT, CME, Open-Meteo; Thống nhất Schema toàn dự án.	Delta Lake core, Bộ script crawlers hoạt động, Landing Bronze Vault.
Sprint 2	Tuần 4 – Tuần 6	TV 3 xây dựng bộ Hợp đồng Great Expectations và OpenLineage; TV 4 triển khai mô hình Star Schema trên chDB và Polars LazyFrame; TV 7 lên khung wireframe UI.	Báo cáo Data Docs HTML, CSDL <code>factory_analytics.chdb</code> , Wireframe Dashboard.
Sprint 3	Tuần 7 – Tuần 9	TV 5 phân tích EDA, tính toán biên kiểm soát SPC Shewhart/CUSUM và C_p/C_{pk} ; TV 6 huấn luyện mô hình Hồi quy tuyến tính có điều chuẩn và Hồi quy Logistic.	Module SPC Nelson Rules, Trọng số mô hình hồi quy, ROC-AUC report.
Sprint 4	Tuần 10 – Tuần 11	TV 6 hoàn thiện thuật toán EM xử lý cảm biến khuyết thiếu; TV 7 tích hợp 4 Tabs lên Plotly Dash, cài đặt cơ chế Reactive Callbacks và nhúng What-If Simulator.	Bản thử nghiệm Beta Plotly Dash chạy trơn tru với phản hồi < 50 ms.
Sprint 5	Tuần 12	Cả 07 thành viên hoàn thành viết chương báo cáo cá nhân bằng $\text{\LaTeX}$; TV 7 thiết kế Master Slide Beamer; Tổ chức ghép nối mã nguồn và tổng duyệt toàn văn.	Toàn văn Dự thảo Báo cáo $\text{\LaTeX}$ và Bộ Master Slide hoàn chỉnh.
Sprint 6	Tuần 13 – Tuần 15	Diễn tập bảo vệ giả lập (Mock Defense) 02 vòng nội bộ; hoàn thiện tài liệu, đóng gói Docker Compose và tham gia bảo vệ chính thức trước hội đồng.	Repository Github chuẩn mực, Containerized App, Hướng tới điểm A/A+.

8 Chiến Thuật Ghi Điểm Tuyệt Đối Trong Phiên Vấn Đáp

Mỗi thành viên trong nhóm rèn luyện kỹ năng phản biện theo **Chiến thuật vấn đáp 3 bước chuẩn mực**:

CHIẾN THUẬT VẤN ĐÁP 3 BƯỚC CHO MỖI THÀNH VIÊN (120 GIÂY)

1. Bước 1: Nêu bật bản chất kỹ thuật / cơ sở lý thuyết (30 giây):

“Thưa thầy, cơ sở lý thuyết cốt lõi trong phân hệ của em là [Kiến trúc Lakehouse / Thuật toán cào dữ liệu Token Bucket / Ràng buộc Great Expectations / SIMD chDB / Giới hạn SPC Shewhart / Hồi quy Logistic & Thuật toán EM / Reactive Callbacks], nhằm giải quyết trực tiếp bài toán công nghiệp là [...]”

2. Bước 2: Giải trình dòng lệnh mã nguồn & Tối ưu hóa kỹ thuật (45 giây):

“Em đã trực tiếp lập trình giải thuật này tại tệp tin [tên_tệp.py], áp dụng [cơ chế Lazy Execution Polars / Transaction log Delta / Scrappy pipeline / Hàm tối ưu chDB] và giải quyết bài toán hiệu năng ở điểm [...]”

3. Bước 3: Diễn giải ý nghĩa trực quan & Giá trị quản trị thực tế (45 giây):

“Kết quả trực quan thu được thể hiện trên biểu đồ [Tên biểu đồ]. Con số này giúp kỹ sư vận hành nhà máy nhận biết được [...] và đưa ra quyết sách can thiệp kịp thời nhằm giảm thiểu rủi ro hao hụt sản phẩm.”

- **Minh bạch tỷ lệ đóng góp:** Slide mở đầu sẽ thể hiện rõ bảng phân công 07 phân hệ độc lập với tỷ lệ $\approx 14.3\%$ cho mỗi thành viên, khẳng định tính toàn vẹn và sự chủ động của từng cá nhân.
- **Khả năng kết nối liên phân hệ:** Mỗi thành viên không chỉ làm chủ phân hệ của mình mà còn nắm vững giao diện trao đổi dữ liệu (Data Interfaces) với các phân hệ lân cận để phối hợp bảo vệ mạch lạc trước hội đồng.

9 Kết Luận

Bản kế hoạch triển khai Bài tập lớn học phần IT5425 trên đây đã xác lập đầy đủ kiến trúc công nghệ, phương pháp luận quản trị dữ liệu lớn, cơ chế thu thập phân tán, phân rõ trách nhiệm khép kín và lộ trình thực thi cho nhóm 07 sinh viên. Dự án đặt trọng tâm vững chắc vào hai trụ cột sống còn là **Quản trị Dữ liệu Lớn** (Data Lakehouse đa tầng, Delta Lake ACID, chDB ClickHouse SIMD, Great Expectations Data Contracts, OpenLineage) và **Trực quan hóa Dữ liệu Công nghiệp** (Plotly Dash reactive architecture, SPC control charts, Interactive What-If Simulator), kết hợp mô hình hóa tuyến tính đúng trọng tâm đề tài. Toàn bộ nhóm tự tin sẽ triển khai thành công một sản phẩm kỹ thuật chất lượng cao, đáp ứng xuất sắc các tiêu chuẩn đánh giá khắt khe nhất của học phần.

Tài liệu

- [1] M. Armbrust, T. Das, L. Sun, B. Yavuz, S. Zhu, M. Murthy, J. Torres, H. van Hovell, A. Ionescu, A. Luszczak, M. Switakowski, M. Szafranski, T. Xiong, and M. Zaharia, “Delta Lake: High-performance ACID table storage over cloud object stores,” in *Proceedings of the VLDB Endowment*, vol. 13, no. 12, pp. 3411–3424, 2020.
- [2] A. Zaitsev and ClickHouse Team, “chDB: In-process SQL OLAP Engine powered by ClickHouse,” *ClickHouse Technical Documentation*, 2023. [Online]. Available: <https://chdb.io>.

- [3] D. C. Montgomery, *Introduction to Statistical Quality Control*, 8th ed., John Wiley & Sons, Hoboken, NJ, 2019.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, New York, NY, 2009.
- [5] A. P. Dempster, N. M. Laird, and D. B. Rubin, “Maximum likelihood from incomplete data via the EM algorithm,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 39, no. 1, pp. 1–38, 1977.
- [6] C. O. Wilke, *Fundamentals of Data Visualization: A Primer on Making Informative and Compelling Figures*, O’Reilly Media, Sebastopol, CA, 2019.
- [7] S. Few, *Information Dashboard Design: Displaying Data for At-a-Glance Monitoring*, 2nd ed., Analytics Press, Burlingame, CA, 2013.
- [8] International Organization for Standardization, *ISO 22000:2018 Food Safety Management Systems – Requirements for Any Organization in the Food Chain*, Geneva, Switzerland, 2018.